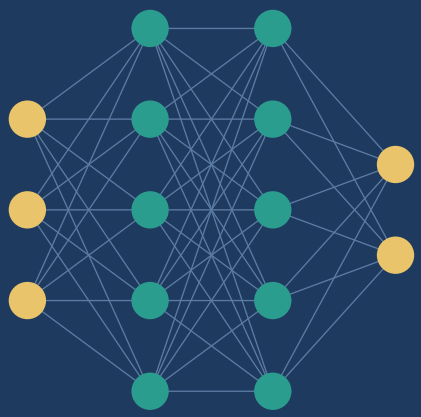
МОДУЛЬ 1 · КАК ДУМАЕТ МАШИНА · УРОК 2

Как работает языковая модель

Токены, вероятности, внимание
и почему ИИ «пишет по одному слову»



О чём этот урок

Заглянем внутрь ChatGPT, Claude и их собратьев. Окажется, что в основе лежит удивительно простая идея — **угадать следующий кусочек текста**. Понимание этой механики — секретное оружие: почти все приёмы промптинга из модуля 2 прямо вытекают из неё.

Главное

После урока вы сможете:

- объяснить, что такое токены и почему модель «пишет по слову»;
- понимать, что такое температура и контекстное окно;
- рассказать, как из «читателя интернета» получается вежливый ассистент;
- сделать из этого 5 практических выводов для работы с ИИ.

Время: ~45 минут чтения + 20 минут практики.

1. Главная идея: угадать продолжение

Большая языковая модель (LLM[1]) делает ровно одну вещь: получает текст и **предсказывает, какой кусочек должен идти следующим**. Добавляет его к тексту — и снова предсказывает. И так, пока ответ не закончится.

Аналогия

Вспомните подсказки клавиатуры в телефоне: вы пишете «Доброе», она предлагает «утро». LLM — это та же идея, только обученная на гигантском объёме текстов и с миллиардами параметров. Настолько хорошо угадывать продолжение можно, только если «понимаешь», о чём речь.

Частое сомнение

«Так это просто продвинутый T9. Он ничего не понимает»

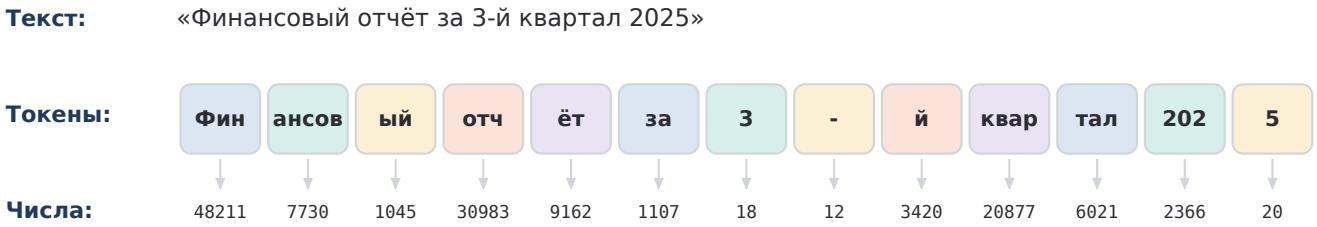
Механика действительно такая — предсказание продолжения. Но чтобы предсказывать хорошо, модели пришлось усвоить закономерности языка, логики и предметных областей: иначе не продолжить расчёт амортизации или разбор договора. Для работы важен не философский вопрос «понимает ли», а измеримый результат — и его можно проверить.

Что здесь справедливо. модель действительно не «понимает» мир как человек и может уверенно ошибаться (урок 3). Поэтому мы относимся к ней как к инструменту, результат которого проверяют.

В разговоре с коллегой: *«Неважно, как это назвать. Давай проверим на твоей задаче, полезен ли результат.»*

2. Токены — «кирпичики» текста

Модель работает не с буквами и не со словами, а с **токенами** — частями слов. Частые слова — один токен, редкие и длинные — несколько. Каждому токену соответствует число: компьютер ведь умеет работать только с числами.



Разбиение условное: у каждой модели свой «словарь» токенов. Числа и окончания вроде «-й» часто режутся на части

Рис. 1. Как текст превращается в токены, а токены — в числа

[1] **LLM** — Large Language Model: большая языковая модель.

Главное

- Лимиты и цены считают **в токенах**, а не в словах или страницах.
- Русский текст обычно дробится на больше токенов, чем английский, — значит, «весит» больше.
- Модели могут ошибаться в задачах на буквы («сколько букв Р в слове…»): они видят не буквы, а токены.

3. Вероятности: модель выбирает из вариантов

На каждом шаге модель не «знает» ответ, а оценивает **вероятность** каждого возможного следующего токена. Затем выбирает один из них и повторяет процесс уже с удлинённым текстом.



«Столица Франции — Париж» → снова в модель → следующий токен… и так, токен за токеном

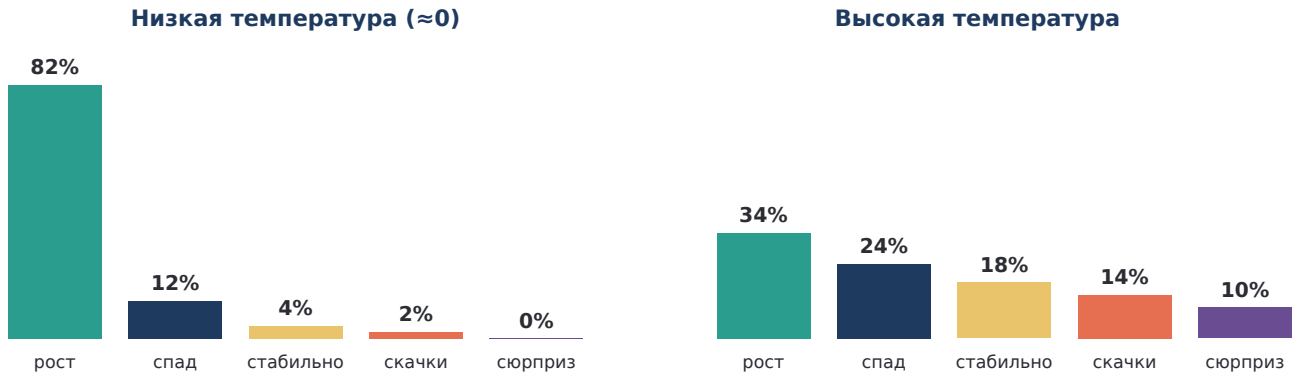
Рис. 2. Модель оценивает вероятности кандидатов и добавляет выбранный токен к тексту

Главное

Ответ рождается по ходу написания. У модели нет заранее готового текста, который она «распечатывает». Поэтому полезно дать ей «подумать» перед ответом — об этом ниже и в уроке 5.

Температура — ручка «предсказуемость / креативность»

Температура — настройка, которая решает, насколько смело модель выбирает менее вероятные варианты.



Пример: продолжение фразы «В следующем квартале ожидается...»

Рис. 3. Низкая температура «заостряет» выбор, высокая — уравнивает шансы

Температура	Поведение	Когда нужна
Низкая	Ответы стабильные, почти одинаковые при повторе	Расчёты, извлечение данных, код, факты
Высокая	Ответы разнообразные, неожиданные, иногда странные	Мозговой штурм, тексты, названия, идеи

Быстро устаревает — проверяйте актуальное

В обычных чат-приложениях температуру часто нельзя менять вручную — её задаёт разработчик. Она доступна через API[2] и в «песочницах» разработчиков. Некоторые новые модели вообще не дают её настраивать.

Частое сомнение

«Он на один и тот же вопрос каждый раз отвечает по-разному. Как этому доверять?»

Разброс — прямое следствие выбора из вероятностей (рис. 2–3). Для творческих задач это плюс: больше вариантов. Для точных задач разброс снижают: чёткий промпт, данные прямо в запросе, расчёт с помощью кода (урок 3). Тогда ответы становятся стабильными.

Что здесь справедливо. «спросить один раз и поверить» действительно нельзя. Важные выводы проверяют — так же, как перепроверяют расчёт коллеги.

В разговоре с коллегой: *«Разные формулировки — это нормально. Для цифр мы просим считать кодом и проверяем.»*

[2] **API** — Application Programming Interface: способ, которым программы обращаются к модели напрямую, без чата.

4. Внимание: как модель понимает контекст

Помните «Трансформер» из урока 1? Его ключевое изобретение — механизм **внимания (attention)**. Обрабатывая каждое слово, модель «смотрит» на все остальные слова текста и решает, какие из них важны для его смысла.



Рис. 4. Одно и то же слово «банке» — разный смысл. Внимание связывает его с нужными соседями (толщина линии = сила связи)

Именно поэтому LLM так хорошо понимают многозначность, отсылки («он», «этот договор») и длинные рассуждения. И поэтому **контекст в запросе так важен**: чем больше полезных «соседей» вы дадите, тем точнее модель поймёт задачу.

5. Как обучают языковую модель

Чат-ассистент получается в три этапа. Каждый следующий тратит меньше данных, но сильно меняет поведение.

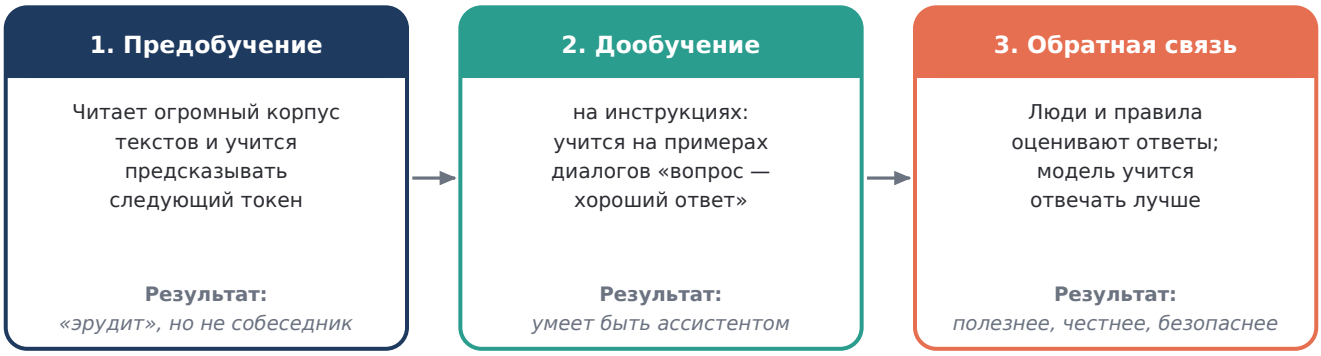


Рис. 5. Три этапа: от «читателя библиотеки» к полезному ассистенту

Аналогия

1. Студент прочитал всю библиотеку — знает очень много, но на вопрос может ответить чем угодно, например продолжить его ещё тремя вопросами. 2. Затем проходит стажировку: видит, как отвечают опытные сотрудники. 3. Наконец, наставник оценивает его работу: «это хорошо, а это — грубо и неверно». Студент учится на оценках.

У предобучения есть конец. Тексты для него собирают до определённого момента, затем модель «замораживают» и дальше только дообучают. Этот момент называют **датой среза**

знаний (knowledge cutoff). О том, что случилось позже, модель знает только то, что вы ей дадите: документ, текст новости или доступ к поиску. Без этого на вопрос о свежих событиях она либо скажет, что не знает, либо — хуже — правдоподобно додумает (подробнее — в уроке 3).

Главное

Что такое «знания» модели

- Знания «сжаты» в параметрах — как опыт человека, а не как файлы на диске.
- У модели есть дата среза знаний: о событиях после неё она не знает, если ей не дать поиск или документы.
- Модель не обучается на ваших разговорах в реальном времени: между чатами она ничего не «помнит», если приложение не добавляет специальную функцию памяти.

6. Контекстное окно — рабочая память

Всё, что модель учитывает при ответе, должно находиться в **контекстном окне**: инструкции, загруженные документы, вся история диалога и сам вопрос. Окно измеряется в токенах.



Не поместилось в окно → модель этого не знает. Новый чат → окно снова пустое

Рис. 6. Контекстное окно: что модель «видит» в момент ответа

Осторожно

- В очень длинных диалогах модель может хуже учитывать детали из начала разговора.
- Если чат «поплыл» — проще начать новый и кратко изложить суть заново.
- Новый чат = чистый лист. Модель не помнит, о чём вы говорили вчера (если нет функции памяти).

Быстро устаревает — проверяйте актуальное

Размер окна быстро растёт: у современных моделей это от сотен тысяч до миллионов токенов — сотни и тысячи страниц. Точные цифры у каждой модели свои и меняются с каждым поколением.

7. Модели, которые «думают»

Раз ответ рождается по ходу письма, то и рассуждение тоже. Если попросить модель сначала расписать ход мыслей, а потом дать ответ, на сложных задачах результат заметно лучше — у неё появляется «черновик».

Современные **рассуждающие модели** делают это сами: перед ответом они генерируют скрытую или видимую цепочку размышлений, проверяют себя и только потом отвечают. Это дольше и дороже, зато точнее в математике, анализе и программировании.

	Быстрый режим	Режим рассуждения
Скорость	Секунды	От десятков секунд до минут
Подходит для	Переписать текст, ответить на простой вопрос, перевести	Сложный анализ, расчёты, план проекта, отладка кода
Аналогия	Ответ «с ходу»	Ответ «дай подумать, возьму листок»

Быстро устаревает — проверяйте актуальное

Как включается «размышление», зависит от продукта: отдельная модель, переключатель в интерфейсе или автоматический выбор. Названия режимов меняются постоянно — суть остаётся.

5 выводов для практики

Всё, что мы разобрали, превращается в простые правила работы с ИИ:

Механика	Что из этого следует для вас
Модель продолжает текст	**Как спросишь, так и ответят.** Стиль, точность и формат вопроса задают стиль ответа
Внимание опирается на контекст	**Давайте контекст:** кто вы, для чего результат, что уже известно. Модель не читает мысли
Ответ рождается по ходу письма	**Просите подумать** на сложных задачах: «сначала разбери по шагам, потом ответь»
Знания сжаты и имеют дату среза	**Проверяйте факты**, цифры и свежие события; давайте документы вместо расчёта на «память» модели
Есть контекстное окно, нет памяти между чатами	**Каждый чат — с нуля.** Длинный запутанный диалог проще перезапустить с кратким резюме

Частое сомнение

«Это игрушка для развлечения. Для серьёзной работы пользы нет»

Пользу проверяли в контролируемых экспериментах: одной группе давали ИИ, другой нет, и сравнивали время и качество работы.

- 453 специалиста с высшим образованием выполняли типичные задания по деловому письму. С ChatGPT они тратили примерно на 40% меньше времени, а качество, по оценке независимых экспертов, выросло на 18%. — *Noy & Zhang, журнал Science, 2023*
- 5179 операторов службы поддержки получили ИИ-помощника. Число решённых обращений в час выросло в среднем на 14%, у новичков — на 34%. У самых опытных эффект был минимальным. — *Brynjolfsson, Li, Raymond, рабочая версия NBER, 2023*

Что здесь справедливо. эффект неравномерный: больше всего выигрывают новички и рутинные задачи, а опытный специалист в своей сильной зоне получает скромную прибавку. Цифры одних задач нельзя переносить на любую работу.

В разговоре с коллегой: *«Это не игрушка, но и не волшебство: на рутине экономия измерена, а в экспертных задачах решаешь всё равно ты.»*

Глоссарий урока

Термин	Простыми словами
LLM	Большая языковая модель: предсказывает следующий токен текста
Токен	Кусочек текста (часть слова), с которым работает модель
Вероятность токена	Оценка модели, насколько уместен каждый вариант продолжения
Температура	Настройка смелости выбора: низкая — предсказуемо, высокая — креативно
Внимание (attention)	Механизм, позволяющий каждому слову учитывать смысл остальных
Трансформер	Архитектура нейросети на основе внимания; основа всех современных LLM
Предобучение	Первый этап: модель читает огромный объём текстов
Обучение с обратной связью	Этап, где модель учится на оценках ответов (людьми или по правилам)
Дата среза знаний	Момент, после которого модель ничего не знает о мире без поиска
Контекстное окно	Объём текста (в токенах), который модель учитывает при ответе
Рассуждающая модель	Модель, которая перед ответом выстраивает цепочку размышлений

Вопросы для самопроверки

1. Опишите одной фразой, что делает языковая модель.
2. Почему лимиты и стоимость использования считают в токенах?
3. Какую температуру вы бы выбрали для извлечения сумм из счетов, а какую — для придумывания названия продукта?
4. Как механизм внимания помогает модели понять слово «ключ» в фразах «ключ от двери» и «ключ к решению»?
5. Чем отличаются этапы предобучения и обучения с обратной связью?
6. Вы вчера обсуждали с ИИ проект, а сегодня в новом чате он «ничего не помнит». Почему?
7. Почему фраза «сначала порассуждай по шагам» улучшает ответы на сложные вопросы?
8. Коллега говорит: «Это просто Т9». Что в этом верно и почему это не мешает использовать ИИ в работе?

Ответы для проверки

Ответы

1. Получает текст и раз за разом предсказывает следующий токен.
2. Потому что модель обрабатывает именно токены: объём работы (и стоимость) пропорционален их числу.
3. Для счетов — низкую (нужна точность и повторяемость). Для названия — высокую (нужно разнообразие).
4. Слово «ключ» связывается вниманием с соседями: «двери» тянет к предмету, «решению» — к переносному смыслу.
5. Предобучение — чтение огромного корпуса текстов, модель учится предсказывать продолжение. Обратная связь — модель учится на оценках, какие ответы лучше.
6. Каждый чат начинается с пустого контекстного окна; модель не дообучается на разговорах (если нет функции памяти).
7. Ответ создаётся по ходу письма: промежуточные шаги становятся частью контекста и помогают прийти к верному выводу.
8. Механика и правда — предсказание продолжения. Но пользу определяет результат, а его можно измерить и проверить: в экспериментах с ИИ работают быстрее и качественнее.

Практика

Практика

Задание 1. Посмотрите на токены (5 мин)

Найдите в поисковике «tokenizer» (онлайн-токенайзер от разработчиков моделей). Вставьте одну и ту же фразу на русском и на английском. Сравните количество токенов.

Задание 2. Эксперимент с повтором (5 мин)

Задайте ИИ один и тот же творческий вопрос три раза в новых чатах: «Придумай 3 названия для сервиса учёта вагонов». Ответы разные? Это и есть вероятностная природа модели.

Практика

Задание 3. «Подумай, прежде чем ответить» (10 мин)

Дайте модели задачу с подвохом в двух вариантах — сначала «ответь одним числом», затем с просьбой рассуждать по шагам. Сравните результаты:

```
Компания купила оборудование за 1 200 000 руб. со сроком
службы 5 лет и ликвидационной стоимостью 200 000 руб.
Амортизация линейная. Через 2 года 9 месяцев оборудование
продали за 700 000 руб. Каков финансовый результат от продажи?
Сначала распиши расчёт по шагам, затем дай ответ.
```

Правильный ответ: амортизация 200 000 в год × 2,75 года = 550 000; остаточная стоимость 650 000; прибыль от продажи 50 000 руб.

Что почитать и посмотреть

- Андрей Карпати, лекция «Intro to Large Language Models» (YouTube) — лучшее часовое введение в LLM.
- 3Blue1Brown, видео о трансформерах и механизме внимания — наглядно и без формул.
- Следующий урок: **«Сильные и слабые стороны ИИ»** — галлюцинации, инструменты и где ИИ доверять нельзя.

Источники фактов

Ссылки кликабельны. Реестр всех фактов урока — в файле docs/facts.md репозитория.

- Noy S., Zhang W. Experimental evidence on the productivity effects of generative artificial intelligence // Science, 2023, т. 381, с. 187–192; вторая ссылка — открытая версия статьи — doi.org/10.1126/science.adh2586 · economics.mit.edu/sites/default/files/inline-files/Noy_Zhang_1_0.pdf
- Brynjolfsson E., Li D., Raymond L. Generative AI at Work // NBER Working Paper 31161, 2023 (цифры урока — из этой версии). В журнальной версии (Quarterly Journal of Economics, 2025) уточнённая выборка — 5172 оператора и +15% в среднем; вывод о большем эффекте у новичков сохранился — nber.org/papers/w31161 · doi.org/10.1093/qje/qjae044