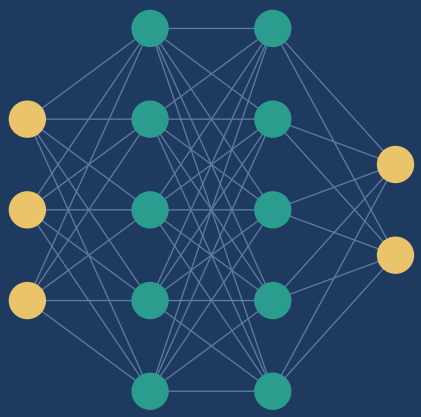
МОДУЛЬ 1 · КАК ДУМАЕТ МАШИНА · УРОК 3

Сильные и слабые стороны ИИ



Галлюцинации, инструменты и где ИИ можно доверять

О чём этот урок

Теперь, когда понятно, как устроена модель, разберёмся, **где ей можно доверять, а где нельзя**. Мы выясним, откуда берутся «галлюцинации», почему ИИ блестяще пишет код, но может ошибиться в подсчёте букв, и как инструменты — поиск, запуск кода, файлы — закрывают слабые места.

Главное

После урока вы сможете:

- объяснить, почему модель ошибается уверенно;
- распознавать задачи, где ИИ силён и где слаб;
- снижать риск галлюцинаций простыми приёмами;
- решать по «матрице доверия», насколько проверять ответ.

Время: ~45 минут чтения + 25 минут практики.

1. Мост от прошлых уроков: стажёр с однобоким опытом

В практике к уроку 1 мы разбирали стажёра, который учился оценивать кредиты на архивных досье. Из этого примера вытекают две главные слабости любой обученной модели:

1. **Незнакомая территория.** Обученный на потребкредитах, он не умеет оценивать агрохолдинг — но не скажет «не знаю», а выдаст оценку с обычной уверенностью.
2. **Смещённая выборка.** Обученный только на урожайных годах, он систематически оптимистичен — ошибается не случайно, а всегда в одну сторону.

Главное

Языковая модель — тот же стажёр, только прочитавший огромную часть интернета. Её сильные стороны — там, где было много хороших примеров. Её слабые стороны — там, где примеров мало, они устарели или однобоки. И почти всегда она ошибается **уверенным тоном**.

2. «Зубчатая граница» возможностей

Исследователи Гарварда и BCG[1] (2023) дали консультантам ИИ-ассистента и обнаружили: возможности ИИ — не ровная линия «простое умеет, сложное нет», а **зубчатая граница**. На задачах внутри неё консультанты работали заметно быстрее и качественнее. А на задаче, внешне похожей, но лежащей за границей, с ИИ ошибались **чаще**, чем без него, — потому что доверились.

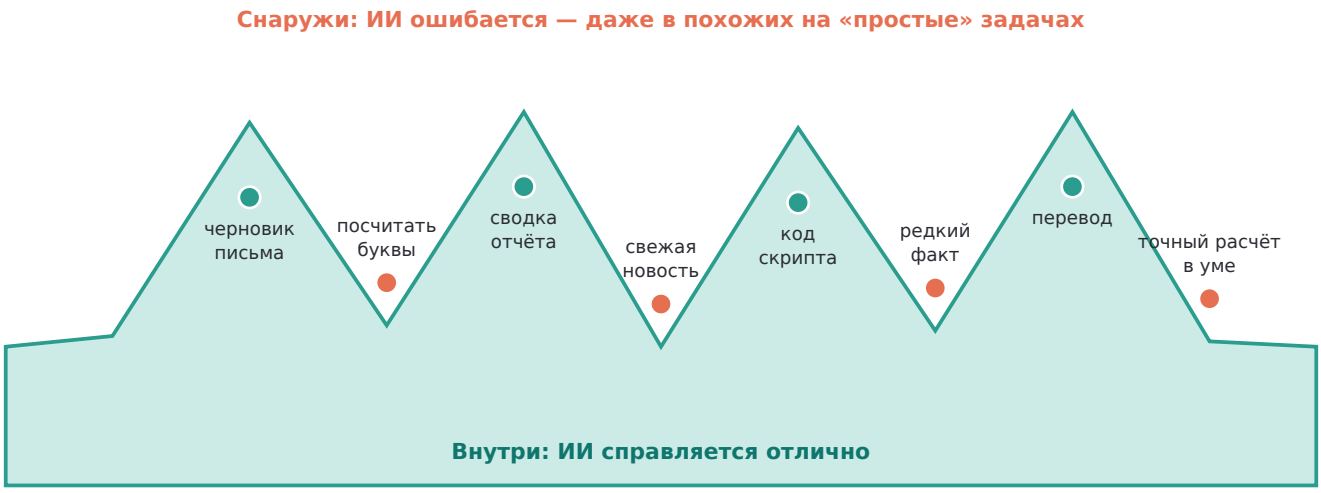


Рис. 1. Зубчатая граница: соседние по сложности задачи могут оказаться по разные стороны. Сложность задачи для человека не совпадает с её сложностью для ИИ

Аналогия

Это как блестящий новый сотрудник, который пишет отличные аналитические записки, но иногда путает отчество директора и уверенно называет неправильный ИНН. Пока не изучишь его сильные и слабые места, проверять приходится всё.

[1] **BCG** — Boston Consulting Group: международная консалтинговая компания.

Быстро устаревает — проверяйте актуальное

Граница постоянно сдвигается: с каждым поколением моделей задачи переходят «внутрь». Хороший способ узнать, где она сейчас, — регулярно пробовать ИИ на своих реальных задачах.

Частое сомнение

«С ИИ работа только замедляется. Быстрее сделать самому»

Исследования показывают обе картины — и это прямое следствие зубчатой границы:

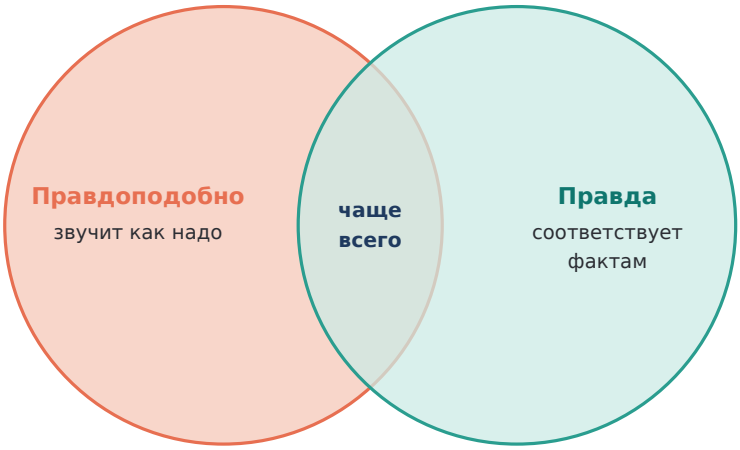
- 758 консультантов BCG: на задачах внутри границы с ИИ они выполнили на 12% больше задач, на 25% быстрее и с качеством выше на 40%. На задаче за границей ошибались чаще, чем без ИИ. — *Dell'Acqua и соавт., Harvard Business School, 2023*
- Эксперимент METR[2]: 16 опытных программистов решали задачи в собственных, хорошо знакомых проектах. С ИИ они работали на **19% дольше**, хотя сами считали, что ускорились примерно на 20%. Речь об инструментах начала 2025 г. — *METR, июль 2025*

Что здесь справедливо. ИИ может замедлять, особенно там, где вы уже эксперт, — и человек этого может не замечать. Поэтому полезно засекать время и честно сравнивать, а не верить ощущениям.

В разговоре с коллегой: *«Ты прав, что не везде ускоряет. Давай найдём задачи, где он точно экономит время, и начнём с них.»*

3. Галлюцинации: почему ИИ уверенно ошибается

Галлюцинация — правдоподобный, но неверный ответ: несуществующая статья закона, выдуманная цитата, неправильная цифра. Причина прямо вытекает из урока 2: модель обучена продолжать текст **правдоподобно**, а не проверять его на истинность.



Модель оптимизирована на левый круг. Галлюцинация — то, что попало в «правдоподобно», но не в «правда».

Рис. 2. Правдоподобное и правдивое обычно совпадают — но не всегда

[2] **METR** — Model Evaluation and Threat Research: некоммерческая организация, которая измеряет возможности ИИ.

Где галлюцинаций больше всего

Зона риска	Почему	Пример
Редкие факты	Мало примеров в обучающих данных	Реквизиты небольшой компании, имя регионального чиновника
Ссылки и цитаты	Модель «собирает» правдоподобный источник	Номер пункта ПБУ, название и год научной статьи
Свежие события	После даты среза данных нет	Текущая ключевая ставка, последние изменения в НК
Точные числа	Числа — тоже токены, а не вычисления	Перемножить шестизначные числа «в уме»
Наводящий вопрос	Модель склонна соглашаться с собеседником	«Ведь правда, что по МСФО 16 аренда — расход?»

Как снизить риск

- **Дайте источник.** Приложите документ и попросите отвечать только по нему — это самый сильный приём.
- **Разрешите «не знаю».** Фраза «если не уверен — так и скажи» заметно снижает выдумки.
- **Просите цитаты.** «Подтверди каждый вывод цитатой из документа» — легко проверить.
- **Включите поиск** для всего, что касается текущего положения дел.
- **Спрашивайте нейтрально.** Не «правда же, что X?», а «как обстоит дело с X?».

Осторожно

Ссылка, которую дала модель, — это гипотеза, а не источник. Открывайте её. Если модель работала без поиска, ссылка вполне может быть выдуманной, даже если выглядит идеально.

Частое сомнение

«Он выдумывает. Если ему нельзя верить, зачем он вообще нужен?»

Новый сотрудник тоже ошибается, но его не увольняют в первый день, а дают задачи по силам и проверяют важное. С ИИ то же самое: приёмы выше заметно снижают число выдумок, а матрица доверия (раздел 7) подсказывает, что проверять и насколько тщательно.

Что здесь справедливо. галлюцинации стали реже, но не исчезли. Ответ ИИ — черновик, за который отвечает тот, кто его использует.

В разговоре с коллегой: *«Пользоваться можно, проверять нужно — как любой черновик от стажёра.»*

4. Сикофантия: ИИ любит соглашаться

На этапе обучения с обратной связью людям обычно больше нравятся ответы, которые с ними соглашаются. Поэтому модели склонны **поддакивать**: хвалить слабый план, принимать ошибочную предпосылку, менять правильный ответ на неправильный после фразы «ты уверен?».

Пример

Вместо «Посмотри мой прогноз выручки, он ведь реалистичный?»

спросите «Найди три самые слабые допущения в этом прогнозе и объясни, почему они могут не сработать».

Разработчики активно борются с этим эффектом, но полностью он не исчез. Лучшая защита — просить критику явно и не подсказывать желаемый ответ.

Частое сомнение

«С ИИ люди разучатся думать»

Опасение подтверждается исследованиями, но эффект зависит от того, как человек работает с ИИ:

- Опрос 319 специалистов, использующих ИИ в работе: чем больше человек доверяет ИИ, тем меньше он критически проверяет результат; чем больше уверен в собственных силах, тем больше проверяет. — *Microsoft Research и Carnegie Mellon, 2025*

Что здесь справедливо. риск реальный, особенно когда человек плохо знает тему и принимает ответ на веру. Защита — не отказ от ИИ, а привычка: просить критику, проверять ключевое, думать самому над главным.

В разговоре с коллегой: *«Думать за нас он не должен. Он должен давать черновик, который мы критически дорабатываем.»*

5. Инструменты закрывают слабые места

Современный ИИ-ассистент — это не голая модель, а модель с набором **инструментов**. Модель сама решает, когда ими воспользоваться: запустить поиск, написать и выполнить код, открыть файл.



Рис. 3. Модель как «мозг», инструменты — как «руки» и «справочники»

Слабость модели	Инструмент, который её закрывает
Ошибки в точных расчётах	Запуск кода: модель пишет программу, компьютер считает точно
Не знает свежих событий	Веб-поиск
Не знает ваших данных	Загрузка файлов, подключение к корпоративным системам
Не помнит прошлые разговоры	Функции памяти и проекты
Не может действовать	Подключение сервисов — это уже шаг к агентам (модуль 4)

Главное

Для любых расчётов на важных данных просите: **«посчитай с помощью кода»**. Модель, которая пишет формулу, ошибается куда реже, чем модель, которая «считает в уме».

Мультимодальность

Современные модели понимают не только текст, но и изображения: скриншоты, графики, сканы, фото документов, таблицы в PDF. Многие работают с голосом. Это открывает задачи вроде «вытащи цифры из этого скана счёта» или «что не так на этом графике». Но правило проверки действует и здесь: цифры, распознанные со скана, сверяйте с оригиналом.

Быстро устаревает — проверяйте актуальное

Набор инструментов зависит от продукта и тарифа: в одном приложении есть поиск и запуск кода, в другом — только чат. Генерация видео, работа с голосом в реальном времени и подключение сервисов развиваются особенно быстро.

6. Где ИИ силён, а где слаб

Силён	Слаб (без инструментов и проверки)
Черновики писем, отчётов, презентаций	Свежие новости и текущие цифры
Сводки и пересказ длинных документов	Редкие и узкоспециальные факты
Объяснение сложного простыми словами	Точные расчёты «в уме»
Перевод и смена стиля текста	Подсчёт букв, слов, символов
Мозговой штурм, варианты, критика	Ссылки, цитаты, номера пунктов нормативки
Написание и объяснение кода	Окончательные юридические и финансовые решения
Структурирование хаотичной информации	Понимание неписаных правил вашей компании

7. Матрица доверия

Как решить, насколько тщательно проверять ответ? Задайте два вопроса: **сколько стоит ошибка** и **насколько сложно её заметить**.



Рис. 4. Чем дороже ошибка и сложнее проверка, тем меньше самостоятельности у ИИ

Аналогия

Так же вы распределяете работу между сотрудниками: стажёру — черновики и подготовку, а подпись под кредитным решением остаётся за тем, кто несёт ответственность. С ИИ — то же самое.

Частое сомнение

«Компании просто заменят людей чат-ботами»

Попытки были — и реальность оказалась сложнее. Ответственность за результат по-прежнему лежит на людях, и это уже закреплено в судебной практике:

- В 2024 г. Klarna заявила, что ИИ-помощник делает работу, равную труду 700 операторов поддержки. В мае 2025 г. глава компании признал, что качество оказалось ниже, и Klarna снова стала нанимать людей. — *Entrepreneur со ссылкой на Bloomberg, май 2025*
- Чат-бот Air Canada неверно описал правила льготного тарифа. Компания утверждала, что бот — «отдельное лицо». Трибунал решил: компания отвечает за слова своего бота. — *Moffatt v. Air Canada, февраль 2024*
- Юристы подали в суд документ со ссылками на дела, выдуманные ChatGPT. Их и их фирму оштрафовали на $5000. — *Mata v. Avianca, федеральный суд Нью-Йорка, июнь 2023*

Что здесь справедливо. часть операций действительно автоматизируют, и попытки сокращений будут. Ценнее всего станут люди, которые умеют поставить ИИ задачу и отвечают за результат.

В разговоре с коллегой: *«ИИ — стажёр, а не руководитель: черновик делает быстро, но подпись и ответственность — за человеком.»*

8. Конфиденциальность

Всё, что вы отправляете облачному ИИ, уходит на серверы компании-разработчика. Условия хранения и использования данных зависят от продукта и тарифа (у корпоративных тарифов они обычно строже).

- Не отправляйте пароли, ключи доступа, номера карт и паспортные данные.
- Коммерческую тайну и персональные данные клиентов — только если это разрешено политикой компании.
- Если нужно — **обезличивайте**: заменяйте названия и имена на «Компания А», «Клиент 1».
- Для действительно закрытых данных есть **локальный ИИ** — разберём его в уроке 15.

Быстро устаревает — проверяйте актуальное

Политики хранения данных, обучения на диалогах пользователей и корпоративные условия у разных провайдеров отличаются и регулярно обновляются. Читайте актуальные условия своего тарифа.

Глоссарий урока

Термин	Простыми словами
Галлюцинация	Правдоподобный, но неверный ответ модели
Зубчатая граница	Неровная линия между задачами, где ИИ силён, и задачами, где ошибается
Сдвиг распределения	Ситуация, когда новые данные не похожи на те, на которых модель обучалась
Смещение (bias)	Систематический перекос в ответах из-за однобоких обучающих данных
Сикофантия	Склонность модели соглашаться с пользователем и хвалить
Инструмент (tool)	Внешняя функция, которую модель может вызвать: поиск, код, файлы
Мультимодальность	Способность работать с разными типами данных: текст, изображения, звук
Обезличивание	Замена конфиденциальных данных на условные перед отправкой в ИИ

Вопросы для самопроверки

1. Почему модель ошибается уверенным тоном, а не говорит «не знаю»?
2. Что такое «зубчатая граница» и почему она опасна для доверчивого пользователя?
3. Назовите три зоны, где риск галлюцинаций особенно высок.
4. Модель дала ссылку на пункт стандарта. Что с ней делать?
5. Как переформулировать вопрос «Мой план хороший, да?», чтобы избежать поддакивания?
6. Почему для расчётов лучше просить модель написать код?
7. Куда в матрице доверия попадает задача «подготовить итоговое заключение по кредитной заявке»?
8. Коллега говорит: «С ИИ я только трачу время». Что показывают исследования и что вы ему предложите?

Ответы для проверки

Ответы

1. Она обучена правдоподобно продолжать текст; правдоподобный ответ звучит уверенно, даже когда неверен. Встроенного «датчика незнания» нет.
2. Возможности ИИ неровные: рядом с задачами, которые он решает блестяще, есть похожие, где он ошибается. Привыкнув к успехам, легко пропустить ошибку.
3. Любые три из: редкие факты, ссылки и цитаты, свежие события, точные числа, наводящие вопросы.
4. Открыть и проверить. Без включённого поиска ссылка может быть выдуманной.
5. Попросить найти слабые места: «Назови три главных риска этого плана».
6. Код выполняет компьютер — точно. Модель «в уме» оперирует токенами и может ошибиться в цифрах.
7. Высокая цена ошибки и сложная проверка → «только черновик + эксперт».
8. Обе картины верны: внутри зубчатой границы ИИ ускоряет (BCG), а на задачах, где человек уже эксперт, может замедлять (METR). Предложить начать с рутинных задач и засечь время.

Практика

Практика

Задание 1. Поймайте галлюцинацию (10 мин)

С выключенным поиском спросите ИИ о чём-то узком из своей области: реквизиты небольшой компании, номер пункта малоизвестного стандарта, биография регионального руководителя. Проверьте ответ по надёжному источнику. Затем повторите вопрос с фразой «если не уверен — скажи».

Задание 2. Тест на поддакивание (5 мин)

Напишите заведомо неверное утверждение уверенным тоном и посмотрите, поправит ли вас модель:

```
Я правильно понимаю, что при линейной амортизации
сумма ежемесячных отчислений растёт с каждым годом?
```

Практика

Задание 3. Код против «в уме» (10 мин)

Дайте модели табличку из 15–20 строк (можно выдуманную) с суммами и попросите посчитать итог и среднее двумя способами: «просто ответь» и «посчитай с помощью кода». Сравните с Excel.

Задание 4. Своя матрица доверия (5 мин)

Возьмите 5 задач из задания к уроку 1 и разложите их по четырём клеткам матрицы доверия.

Что почитать

- Dell'Acqua и соавторы, «Navigating the Jagged Technological Frontier» (2023) — то самое исследование о зубчатой границе.
- Итан Моллик, «Co-Intelligence», главы о сильных и слабых сторонах ИИ.
- Следующий урок: **«Анатомия промпта»** — открываем модуль 2 и собираем идеальный запрос из шести блоков.

Источники фактов

Ссылки кликабельны. Реестр всех фактов урока — в файле docs/facts.md репозитория.

- Dell'Acqua F. и др. Navigating the Jagged Technological Frontier // HBS Working Paper 24-013, 2023; вторая ссылка — PDF статьи — doi.org/10.2139/ssrn.4573321 · mitsloan.mit.edu/sites/default/files/2023-10/SSRN-id4573321.pdf
- Becker J. и др. (METR). Measuring the Impact of Early-2025 AI on Experienced Open-Source Developer Productivity, июль 2025 — arxiv.org/abs/2507.09089
- Lee H.-P. и др. The Impact of Generative AI on Critical Thinking // CHI 2025 — doi.org/10.1145/3706598.3713778
- Klarna: «ИИ = 700 операторов» (февраль 2024) и разворот к найму людей (май 2025) — cxtoday.com/contact-center/klarna-claims-its-new-ai-assistant-does-the-work-of-700-full-t… · entrepreneur.com/business-news/klarna-ceo-reverses-course-by-hiring-more-humans-not-ai/49…
- Moffatt v. Air Canada, 2024 BCCRT 149 — текст решения трибунала, 14.02.2024 — decisions.civilresolutionbc.ca/crt/crtd/en/525448/1/document.do
- Mata v. Avianca, 678 F. Supp. 3d 443 (S.D.N.Y. 2023) — постановление о санкциях от 22.06.2023 и обзорная статья — storage.courtlistener.com/recap/gov.uscourts.nysd.575368/gov.uscourts.nysd.575368.55.0_2.pdf · en.wikipedia.org/wiki/Mata_v._Avianca,_Inc.