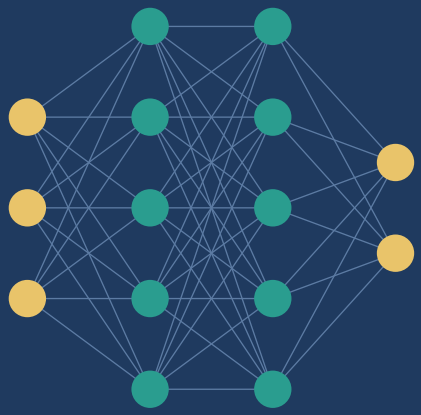
МОДУЛЬ 2 · РАЗГОВОР С МОДЕЛЬЮ · УРОК 6

Документы и данные

Отчёты, договоры и таблицы:
как дать их модели и проверить результат



О чём этот урок

До сих пор мы писали промпты «с нуля». В работе почти всегда есть **материал**: отчётность заёмщика, договор поставки, выгрузка проводок, акты ремонта вагонов. В этом уроке разберём, как модель читает документы, как задавать вопросы так, чтобы ответ можно было проверить, как вытаскивать данные в таблицы и что делать с длинными текстами и разными версиями одного договора.

Главное

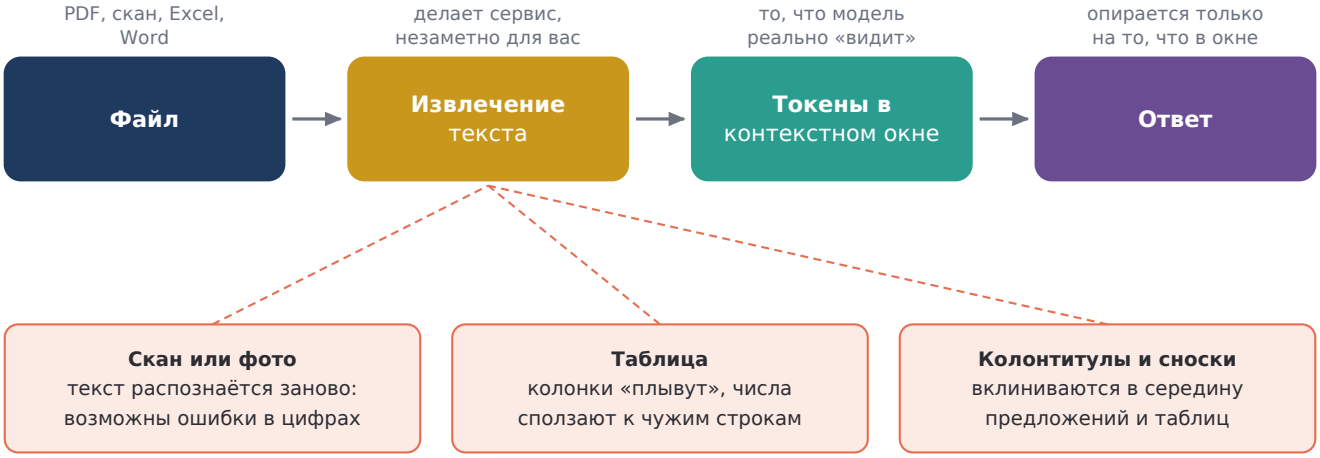
После урока вы сможете:

- понимать, что модель «видит» в загруженном файле и где он искажается;
- получать ответы по документу с опорой на цитаты;
- извлекать данные из пачки документов в таблицу и проверять её;
- работать с длинными отчётами и сравнивать версии договоров.

Время: ~45 минут чтения + 30 минут практики.

1. Как модель «видит» документ

Когда вы прикладываете файл к чату, модель не открывает его, как вы в программе. Сервис сначала **извлекает из файла текст**, а модель получает уже этот текст в виде токенов — в своё контекстное окно (урок 2). Всё, что потерялось или исказилось при извлечении, для модели не существует.



Модель не видит исходный файл — только текст, который из него извлекли

Рис. 1. Путь документа к модели. Слабое место — извлечение текста

Три типичных места, где смысл теряется:

- **Сканы и фото.** Текст в них — картинка. Его распознают заново (технология OCR[1]) или модель «смотрит» на изображение сама (урок 3, мультимодальность). Ошибка в одной цифре суммы при этом вполне возможна.
- **Таблицы.** При извлечении из PDF колонки могут «поплыть»: число из колонки «2025» оказывается рядом с подписью «2024». Таблица выглядит целой, но модель видит её иначе.
- **Колонтитулы, сноски, номера страниц.** Они вклиниваются в середину предложений и таблиц и сбивают модель с толку.

Главное

Модель отвечает не по вашему файлу, а по тексту, который из него извлекли. Если документ — скан или в нём сложные таблицы, первым делом попросите модель **пересказать или выписать то, что она видит**, и сверьте с оригиналом.

Быстро устаревает — проверяйте актуальное

Какой объём файлов принимает чат, какие форматы читает, умеет ли распознавать сканы, есть ли «проекты» с постоянной базой документов — у каждого сервиса своё, и всё это меняется каждые несколько месяцев. Смотрите справку сервиса, которым пользуетесь.

[1] **OCR** — Optical Character Recognition: оптическое распознавание символов, перевод картинки с текстом в текст.

2. Подготовка: что и как давать модели

Хороший результат начинается до промпта — с того, **в каком виде** вы даёте данные.

Что есть	Как лучше дать модели	Почему
Таблица в Excel	Выгрузка в CSV[2] или сам файл .xlsx	Структура сохраняется, числа не «плывут»
Скриншот таблицы	По возможности — исходный файл	На картинке числа распознаются заново
PDF-отчёт с текстовым слоем	Сам PDF	Текст извлекается без распознавания
Скан договора	Скан + просьба сначала выписать текст	Ошибки распознавания видны сразу
Отчёт на 200 страниц	Только нужные разделы или по частям	Меньше шума, выше точность (раздел 5)

И три привычки:

1. **Скажите, что это за документ:** «Баланс по российским стандартам бухгалтерского учёта (РСБУ) за 2024–2025 гг., тыс. руб.». Единицы измерения и период модель иначе угадывает — и иногда неверно.
2. **Уберите лишнее:** служебные листы, черновые расчёты, дубли. Чем меньше шума, тем точнее ответ.
3. **Обезличьте** (урок 3): названия контрагентов, ИНН, фамилии — замените на «Компания А», «Заёмщик Б», если правила компании не разрешают иное.

Частое сомнение

«Загружать рабочие документы в ИИ — значит слить их наружу»

Риск реальный, и начинать нужно с него. Публичный чат-сервис хранит загруженные данные на своих серверах, а в некоторых тарифах может использовать их для обучения. Поэтому вопрос не «можно ли вообще», а «какие документы, в каком сервисе и в каком виде».

- Весной 2023 г. инженеры Samsung загрузили в ChatGPT внутренний исходный код. После этого компания запретила сотрудникам генеративный ИИ на рабочих устройствах: данные уходят на внешние серверы, и удалить их оттуда трудно. *— Bloomberg, май 2023 (в изложении Forbes Australia)*

Что здесь справедливо. опасение обоснованное. Защита — правила компании, корпоративные тарифы с отключённым обучением на ваших данных, обезличивание и локальный ИИ, который работает без интернета (урок 15). Без разрешения службы безопасности рабочие документы в публичный чат не загружаем.

В разговоре с коллегой: *«Давай сначала уточним у безопасников, какой сервис можно использовать, и уберём из документа названия и суммы.»*

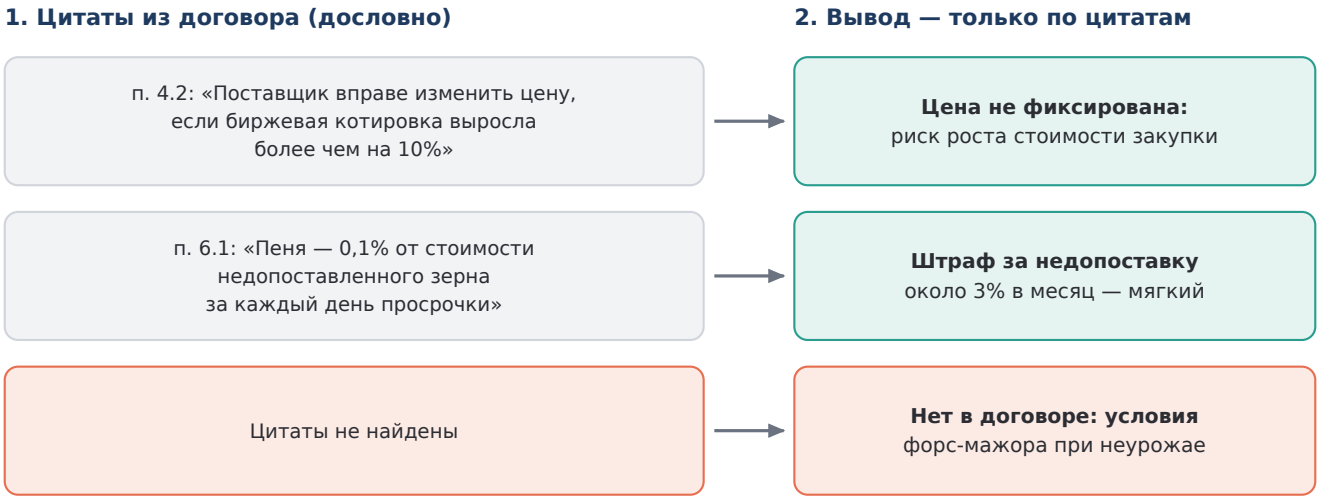
[2] **CSV** — Comma-Separated Values: текстовая таблица со значениями через запятую или точку с запятой; её открывает Excel.

3. Вопросы к документу: ответ с опорой на текст

Самый частый сценарий — спросить что-то о документе: «Какие у поставщика основания поднять цену?», «Как изменилась долговая нагрузка?». Главная опасность здесь — ответ, который **звучит** как вывод из документа, а на деле додуман (урок 3). Защита — заставить модель опираться на текст.

Приём «сначала цитаты»

Попросите модель сначала выписать **дословные цитаты** с номерами пунктов или страниц и только потом сделать вывод — строго по ним. Если нужного в документе нет, пусть так и напишет. Этот приём советуют и разработчики моделей для длинных документов.



Каждый вывод можно проверить за секунды: открыть пункт договора и прочитать

Рис. 2. Вывод привязан к цитате; если цитаты нет, модель честно говорит «нет в договоре»

```
Договор:
[текст договора поставки зерна]

Найди в договоре все условия, при которых поставщик может
изменить цену или объём поставки.
Сначала выпиши дословные цитаты под заголовком «Цитаты»,
у каждой — номер пункта. Затем под заголовком «Выводы»
объясни, что они значат для покупателя, — только по этим
цитатам. Если какого-то условия в договоре нет, напиши
«нет в договоре», ничего не додумывай.
```

Пример

Проверка занимает секунды: открываете пункт 4.2 и читаете своими глазами. Если цитаты в документе нет или она звучит иначе — вывод недостоверен, даже если выглядит убедительно.

Осторожно

Цитату тоже нужно найти в тексте. Модель может «процитировать» то, чего нет в документе, особенно если файл длинный или плохо распознан. Поиск по документу (Ctrl+F) по нескольким словам цитаты — самая быстрая проверка.

4. Извлечение данных в таблицу

Вторая частая задача — вытащить одни и те же поля из пачки документов: суммы из счетов, даты и виды ремонта из актов, ключевые показатели из отчётности нескольких заёмщиков. Модель делает это быстро, но результат стоит ровно столько, сколько стоит его проверка.



Рис. 3. Схема полей задаётся заранее, а таблица проходит два контроля

Как поставить задачу:

- **Схема полей заранее:** какие колонки, в каком порядке, в каких единицах (руб. или тыс. руб., с НДС или без), формат дат.
- **Один документ — одна строка.** Если в акте два ремонта — две строки, и это надо оговорить.
- **«н/д» вместо догадки:** если поля в документе нет, модель пишет «н/д», а не подставляет правдоподобное значение.
- **Колонка «источник»:** имя файла или номер страницы — чтобы любую строку можно было проверить.

```
Акты:
[тексты актов ремонта вагонов]

Составь таблицу по актам, одна строка — один ремонт.
Колонки: номер вагона | дата (ДД.ММ.ГГГГ) | вид ремонта |
сумма, руб., без НДС | файл.
Если значения в акте нет — пиши «н/д». Ничего не округляй.
Ответ — только таблица, без комментариев.
```

Как проверить:

1. **Контрольная сумма.** Итог по таблице должен совпасть с итогом из реестра или бухгалтерии. Считать итог лучше кодом или в Excel, а не просить модель «сложить в уме» (урок 3).
2. **Выборочная сверка.** 5–10 случайных строк — глазами с исходными документами, особенно сканы.
3. **Подозрительные места.** Все «н/д», слишком круглые и слишком большие суммы — проверить отдельно.

5. Длинные документы

Контекстное окно современных моделей вмещает сотни страниц. Но «вмещает» не значит «одинаково внимательно читает». Исследования показывают: информацию из начала и конца длинного текста модели используют лучше, чем из середины.

Что помогает:

- **Документ — в начале, вопрос — в конце** (урок 4).
- **Цитаты** (раздел 3): модель сначала ищет нужные места, потом рассуждает.
- **Только нужное:** для вопроса о долговой нагрузке не нужен раздел о социальной политике.
- **Сводка по частям** для очень длинных документов — цепочка из урока 5.



Рис. 4. Сводка по частям: каждая часть отвечает на один и тот же вопрос, потом ответы сводятся

На рис. 4 каждая часть отчёта отправляется отдельным промптом с одним и тем же вопросом — например, «выпиши все упоминания о долговых обязательствах и залогах, с номерами страниц». Затем частные сводки сводятся в общую. Каждое звено короткое, а значит, внимательное.

Частое сомнение

«Длинный отчёт он всё равно не прочитает целиком»

Отчасти так и есть: модель «видит» весь текст в окне, но не одинаково внимательно. Поэтому для длинных документов работают приёмы выше — цитаты, вопрос в конце и сводка по частям.

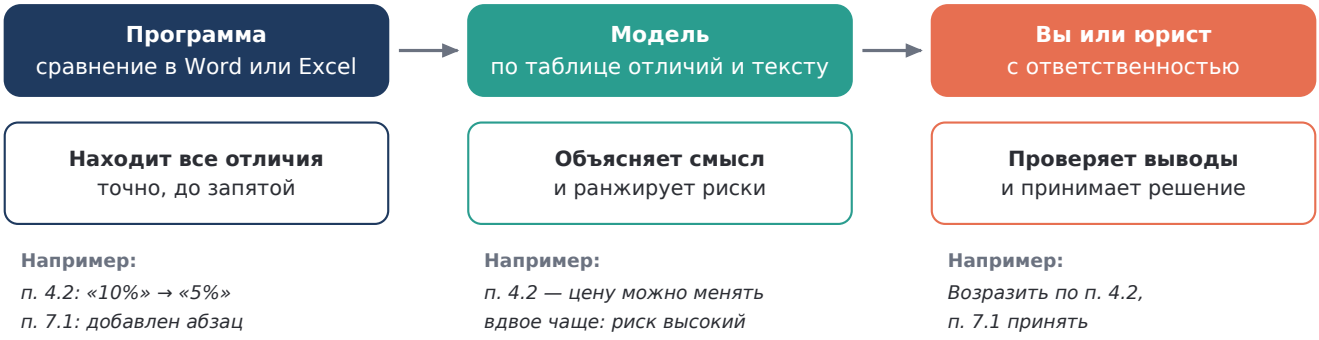
- Модели лучше всего используют информацию из начала и конца длинного текста. Если нужный фрагмент оказывается в середине, точность заметно падает — даже у моделей, созданных для длинных текстов. *— Liu и др., «Lost in the Middle», журнал TACL, 2024*

Что здесь справедливо. на сотнях страниц пропуски действительно случаются. Новые модели справляются заметно лучше, чем те, что изучали в 2023 г., но проверять это стоит на своих документах: спросите о факте из середины отчёта, который вы знаете сами.

В разговоре с коллегой: *«Давай не будем давать ему все 200 страниц: возьмём нужные разделы и попросим цитаты.»*

6. Сравнение версий

Контрагент вернул договор «с небольшими правками». Просить модель найти отличия «на глаз» в двух длинных текстах — рискованно: она может пропустить изменённую цифру. Надёжнее разделить работу.



Модель не ищет отличия «на глаз» — их находит программа; модель их объясняет

Рис. 5. Программа находит отличия, модель объясняет, решение — за человеком

1. **Найти отличия программой.** В Word — «Рецензирование → Сравнить», для таблиц — сравнение файлов в Excel. Это точно и бесплатно.
2. **Отдать модели список отличий и текст договора** и попросить объяснить смысл каждого изменения для нас.
3. **Решить самому** — или вместе с юристом.

```
Договор (новая версия):
[текст]

Изменения относительно прошлой версии:
[список правок из режима сравнения Word]

Для каждого изменения составь строку таблицы:
пункт | было | стало | что это значит для покупателя |
риск (высокий / средний / низкий).
Отсортируй по риску. Если смысл правки неясен — так и напиши.
```

Частое сомнение

«Раз ИИ сравнил договоры и нашёл риски, юристу можно не читать»

Это сомнение «наоборот» — не в том, что ИИ бесполезен, а в том, что ему можно доверить всё. Модель хорошо делает первый проход: находит, объясняет, сортирует. Но ошибка в договоре стоит дорого, а заметить её трудно — это верхний правый угол матрицы доверия (урок 3).

- В 2025 г. в отчёте Deloitte для правительства Австралии нашлись ссылки на несуществующие научные работы и выдуманная цитата из решения суда. Компания вернула последний платёж по контракту на 440 тыс. австралийских долларов, а в исправленной версии указала, что использовала ИИ. *— Associated Press, октябрь 2025*

Что здесь справедливо. ИИ действительно экономит часы на первом проходе, и отказываться от этого незачем. Но читает, проверяет и подписывает человек — и отвечает тоже он.

В разговоре с коллегой: *«Пусть ИИ подготовит таблицу правок, а читать и решать будем мы.»*

7. Чек-лист проверки результата

Насколько глубоко проверять, подскажет матрица доверия из урока 3. Для работы с документами проверка обычно складывается из пяти пунктов:

Что проверить	Как
Модель видит то же, что и вы	Попросить пересказать или выписать фрагмент, сверить со сканом или таблицей
Цитаты существуют	Найти 2–3 цитаты в документе поиском (Ctrl+F)
Цифры совпадают	Сверить ключевые числа с источником; итоги — контрольной суммой
Пропуски видны	Все «н/д» и «нет в документе» — проверить отдельно, не додумывать
Расчёты верны	Пересчитать кодом или в Excel, а не «в уме» модели

Главное

Работа с документами — это цепочка «извлечь → проверить → сделать вывод». Модель ускоряет первое и третье звено, а проверка посередине остаётся за вами. Именно она отличает рабочий инструмент от красивого, но ненадёжного текста.

Глоссарий урока

Термин	Простыми словами
Извлечение текста	Превращение файла (PDF, Word, скан) в текст, который видит модель
OCR	Распознавание текста на картинке или скане
Текстовый слой PDF	Текст внутри PDF, который можно выделить и скопировать; у скана его нет
CSV	Простая текстовая таблица: значения через запятую или точку с запятой
Схема полей	Заранее заданный список колонок, единиц и форматов для извлечения данных
«н/д»	Явная пометка «нет данных» вместо догадки модели
Опора на цитаты	Приём: сначала дословные цитаты с номерами пунктов, потом вывод только по ним
Контрольная сумма	Сверка итога по таблице с независимым итогом (реестр, бухгалтерия)
Сводка по частям	Длинный документ делится на части, по каждой — сводка, потом общая
Сравнение версий	Поиск отличий между редакциями документа — программой, а не «на глаз»

Вопросы для самопроверки

1. Почему модель может ошибиться в таблице, которая в PDF выглядит идеально?
2. Что лучше дать модели: скриншот таблицы или выгрузку из Excel? Почему?
3. Как устроен приём «сначала цитаты» и как быстро проверить его результат?
4. Зачем при извлечении данных просить «н/д» вместо пустой ячейки или догадки?
5. Какие два контроля стоит провести для таблицы, извлечённой из 40 актов?
6. Почему для отчёта на 200 страниц полезна сводка по частям?
7. Кто ищет отличия между версиями договора, кто их объясняет, а кто решает?

Ответы для проверки

Ответы

1. Модель видит не таблицу, а извлечённый из неё текст. При извлечении колонки могут сместиться, и число окажется рядом с чужой подписью.
2. Выгрузку: структура сохраняется, а на картинке числа приходится распознавать заново — с риском ошибки.
3. Модель сначала выписывает дословные цитаты с номерами пунктов, потом делает вывод только по ним. Проверка — найти цитаты в документе поиском и прочитать пункт.
4. Чтобы пропуск был виден сразу. Иначе модель может подставить правдоподобное, но неверное значение.
5. Сверить итоговую сумму с реестром (итог считать кодом или в Excel) и выборочно сверить 5–10 строк с исходными актами.
6. Модели хуже используют информацию из середины длинного текста. Короткие части читаются внимательнее, а частные сводки потом сводятся в общую.
7. Отличия находит программа (сравнение в Word или Excel), смысл объясняет модель, решение принимает человек — вы или юрист.

Практика

Практика

Задание 1. Вопросы с цитатами (10 мин)

Возьмите обезличенный договор или его фрагмент. Задайте модели три вопроса по образцу из раздела 3: сначала цитаты с номерами пунктов, потом выводы. Найдите каждую цитату в тексте поиском. Все ли нашлись дословно?

Задание 2. Таблица из документов (15 мин)

Возьмите 10 однотипных документов (счета, акты, накладные) и извлеките из них таблицу по схеме полей с колонкой «файл». Сверьте итоговую сумму с вашим реестром и проверьте три случайные строки. Где модель ошиблась или поставила «н/д»?

Практика

Задание 3. Сравнение версий (10 мин)

Возьмите две версии одного документа. Сначала сравните их встроенной функцией Word, затем отдайте модели список правок по образцу из раздела 6. Совпадает ли её оценка рисков с вашей?

Задание 4. Что видит модель (5 мин)

Загрузите скан или PDF с таблицей и попросите: «Перепиши таблицу со страницы 3 как есть, ничего не исправляя». Сравните с оригиналом — так вы узнаете, насколько можно доверять этому сервису на ваших документах.

Что почитать

- Официальное руководство Anthropic по промптингу — docs.claude.com, раздел о работе с длинным контекстом (длинные документы, опора на цитаты).
- Liu и др., «Lost in the Middle: How Language Models Use Long Contexts» (2024) — откуда взялся совет не прятать важное в середину.
- Справка вашего ИИ-ассистента о загрузке файлов: форматы, объёмы, хранение данных.
- Следующий урок: **«Контроль качества»** — как систематически проверять ответы, системные промпты и собственные ассистенты.

Источники фактов

Ссылки кликабельны. Реестр всех фактов урока — в файле docs/facts.md репозитория.

- Samsung bans ChatGPT among employees after sensitive code leak // Forbes Australia по материалам Bloomberg, май 2023 — forbes.com.au/news/innovation/samsung-bans-chatgpt-among-employees-after-sensitive-code-leak
- Liu N. F. и др. Lost in the Middle: How Language Models Use Long Contexts // Transactions of the ACL, 2024, т. 12, с. 157–173; вторая ссылка — препринт — aclanthology.org/2024.tacl-1.9 · arxiv.org/abs/2307.03172
- Associated Press: Deloitte to partially refund Australian government for report with apparent AI-generated errors, 07.10.2025 — ctvnews.ca/business/article/deloitte-to-partially-refund-australian-government-for-report…