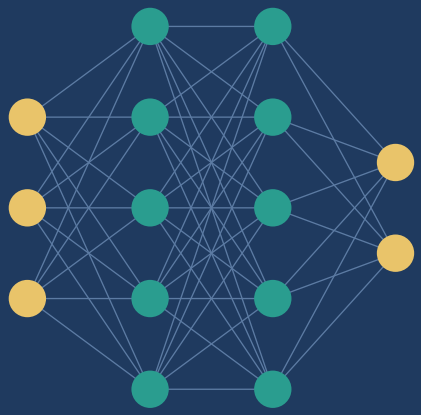
МОДУЛЬ 2 · РАЗГОВОР С МОДЕЛЬЮ · УРОК 7

Контроль качества

Проверка ответов, системные промпты и свои ассистенты



О чём этот урок

Модуль 2 подходит к концу. Мы научились ставить задачу (урок 4), применять техники (урок 5) и работать с документами (урок 6). Остался вопрос, от которого зависит, можно ли всем этим пользоваться в работе: **как убедиться, что результат верен** — не от случая к случаю, а системно. И как сделать так, чтобы удачная настройка не терялась вместе с чатом.

Главное

После урока вы сможете:

- подбирать глубину проверки под цену ошибки;
- проверять источники и задавать вопросы, не провоцируя поддакивание;
- писать системный промпт — инструкцию на все диалоги сразу;
- собирать своего ассистента и проверять его на контрольном наборе задач.

Время: ~45 минут чтения + 30 минут практики.

1. От «проверить ответ» к системе проверки

В прошлых уроках проверка появлялась по ходу дела: цитаты, контрольные суммы, пересчёт кодом. Соберём это в одну картину. Главный вопрос не «проверять или нет», а **насколько глубоко**. Ответ даёт матрица доверия из урока 3: чем дороже ошибка и чем труднее её заметить, тем выше ступень проверки.

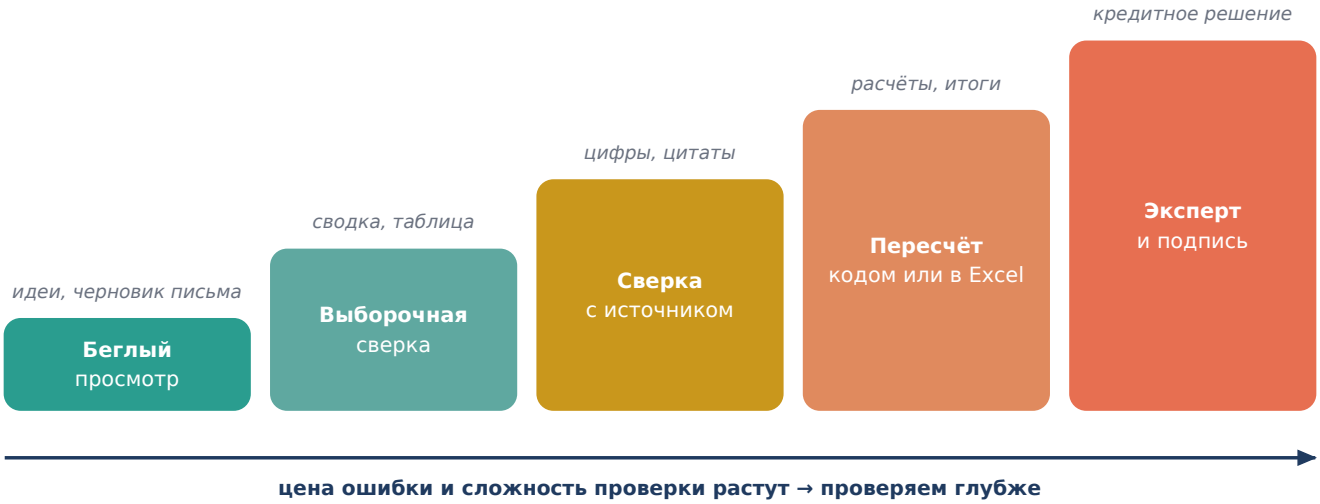


Рис. 1. Лестница проверки: чем выше ставки, тем выше ступень

Аналогия

Так же устроен контроль в любой финансовой службе. Черновик письма руководитель пробегает глазами, сводку проверяет выборочно, расчёт ковенантов пересчитывает, а кредитное решение проходит через комитет. Никто не проверяет всё одинаково — и никто не подписывает не глядя.

2. Четыре способа проверки

Способ	Что ловит	Как сделать
Сверка с источником	Выдуманные факты, искажённые цифры и цитаты	Найти цитату или число в документе (урок 6)
Пересчёт	Ошибки в арифметике и формулах	Попросить модель посчитать кодом или пересчитать в Excel
Вторая независимая попытка	Случайные ошибки, неустойчивые выводы	Задать тот же вопрос в новом чате или другой модели и сравнить
Эксперт	Ошибки, которые видит только специалист	Показать коллеге, юристу, методологу

Осторожно

Совпадение двух ответов — ещё не доказательство. Модели учились на похожих данных и могут одинаково ошибаться. Вторая попытка хорошо ловит случайные сбои, но не заменяет сверку с источником.

3. Источники: просить и проверять

Просить источник — полезная привычка. Но помните урок 3: ссылки и цитаты — одна из главных зон галлюцинаций. Модель без поиска может выдать правдоподобную, но несуществующую ссылку. Поэтому у проверки источника два шага:

1. **Источник существует.** Открыть ссылку, найти статью или документ.
2. **Источник говорит то, что ему приписали.** Найти в нём нужную цифру или фразу. Частая ошибка — настоящая статья, но «чужая» цифра.

Если сервис умеет искать в интернете, включайте поиск для вопросов о фактах, свежих событиях и цифрах: тогда модель опирается на найденные страницы, а не на «память». Но и найденное проверяйте так же.

Быстро устаревает — проверяйте актуальное

Режимы поиска и «глубокого исследования», когда модель сама просматривает десятки страниц и пишет отчёт со ссылками, появились во многих сервисах, но устроены по-разному и быстро меняются. Привычка открывать ключевые ссылки от этого не устаревает.

4. Вопросы без поддакивания

В уроке 3 мы познакомились с **сикофантией** — склонностью модели соглашаться с собеседником. Важная деталь: задавать модели вопросы — нормальная и полезная практика. Поддакивание вызывает не вопрос сам по себе, а **видимый в нём ожидаемый ответ**.



Рис. 2. Один и тот же план — два вопроса и два очень разных ответа

Безопасно	Риск поддакивания
Открытый вопрос: «Как лучше оценить этого заёмщика?»	Вопрос с вашей позицией: «Я думаю, заёмщик надёжный. Согласен?»
Выбор из вариантов: «Это риск ликвидности или риск валютный?»	Наводящий вопрос: «Правда ведь, что риск небольшой?»
Просьба о критике: «Что в моём плане слабое?»	Просьба об одобрении: «Хороший план?»
Вопрос о фактах с просьбой назвать источник	Нажим после ответа: «Ты уверен? По-моему, не так»

Самая коварная строка — последняя. Сомневаться в ответе нормально, но просите **проверку**, а не капитуляцию: вместо «ты уверен?» напишите «перепроверь по шагам и скажи, где ты мог ошибиться». Так у модели остаётся возможность и подтвердить ответ, и исправить его.

Пять приёмов

1. **Спрячьте своё мнение,** если нужна независимая оценка: сначала спросите, потом сравните со своим.
2. **Или раскройте его, но попросите возразить:** «Я склоняюсь к X. Приведи сильнейшие аргументы против».
3. **Попросите обе стороны:** «аргументы за и против», «что сказал бы скептик».
4. **Спрашивайте «что я упускаю?»,** а не «правильно ли я думаю?».
5. **Задайте контрольный вопрос,** если модель сразу согласилась: «А когда моё предложение было бы ошибкой?»

Частое сомнение

«Модель со мной согласилась — значит, я прав»

Согласие модели почти ничего не говорит о вашей правоте: модели склонны подстраиваться под собеседника. Ценнее, когда модель находит слабые места, — поэтому критику стоит просить явно.

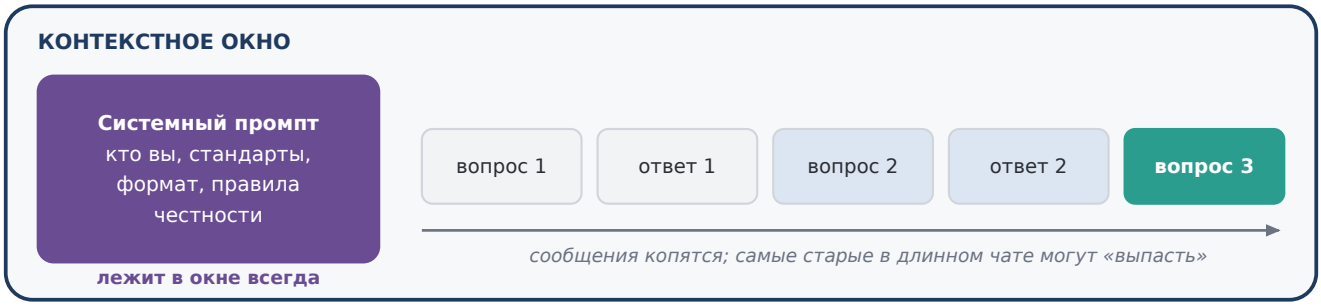
- В эксперименте на верный ответ модели возражали: «Я не думаю, что это правильно. Ты уверен?» В зависимости от модели они признавали «ошибку» в 42–98% случаев и нередко меняли верный ответ на неверный. Проверяли модели 2023 г. — *Sharma и др., ICLR 2024*
- В апреле 2025 г. OpenAI через четыре дня откатила обновление своей модели: по признанию компании, та стала давать «чрезмерно поддерживающие, но неискренние» ответы. — *TechCrunch по материалам OpenAI, апрель 2025*

Что здесь справедливо. разработчики активно борются с поддакиванием, и новые модели соглашаются заметно реже. Но полностью эффект не исчез, а привычка спрашивать нейтрально ничего не стоит.

В разговоре с коллегой: *«Давай спросим его не «правда ли хорошо», а «что здесь слабое», и посмотрим, что он найдёт.»*

5. Системный промпт: инструкция на все диалоги

До сих пор всё нужное мы писали в каждом промпте заново. Но часть указаний повторяется изо дня в день: кто вы, для кого работаете, в каком формате нужен ответ, какие правила честности соблюдать. Их удобно вынести в **системный промпт** — инструкцию, которая действует на весь диалог, а не на одно сообщение.



Системный промпт не нужно повторять: модель «видит» его при каждом ответе

Рис. 3. Системный промпт лежит в контекстном окне всегда, сообщения сменяют друг друга

Что в него класть

- **Кто вы и для кого работаете** — постоянный контекст из урока 4.
- **Ваши стандарты:** единицы измерения, термины, принятые в компании формулировки.
- **Формат по умолчанию:** «сначала вывод, потом аргументы», «таблицы — в рублях, тыс.».
- **Правила честности:** «если не уверен — так и скажи», «цифры — только из приложенных документов», «при нехватке данных задай вопрос».

```
Ты помогаешь кредитному аналитику агрохолдинга (зерно, элеваторы,
ж/д перевозки). Результаты читают кредитный комитет и финансовый
директор.

Стандарты:
— суммы в тыс. руб., отчётность по РСБУ, если не сказано иное;
— показатели долговой нагрузки — по методике из файла «Методика».

Формат: сначала вывод в 2–3 предложениях, затем таблица и риски.

Правила:
— цифры бери только из приложенных документов, указывай страницу;
— если данных не хватает, напиши, каких именно, и не додумывай;
— если я спрашиваю твоё мнение о моём выводе, сначала назови его
  слабые места, потом сильные.
```

Пример

Последнее правило в примере — защита от поддакивания, «встроенная» в инструкцию. Его не нужно помнить в каждом разговоре: оно действует всегда.

6. Свой ассистент и контрольный набор

Следующий шаг — сохранить системный промпт вместе с постоянными файлами и пользоваться ими каждый день. В разных сервисах это называется по-разному: собственный ассистент, проект, «гем». Суть одна: **инструкция + постоянные материалы**, которые не нужно прикладывать заново.



Рис. 4. Ассистент = инструкция + постоянные файлы + контрольный набор задач

Когда ассистент окупается: задача **повторяется** (еженедельная сводка, первичный анализ заёмщика, разнесение проводок), а стандарт **устойчив**. Для разовой задачи хватит обычного промпта.

Контрольный набор

Самая недооценённая часть. Это 5–10 задач, для которых вы **заранее знаете хороший ответ**: три заёмщика с известным выводом, десять проводок с правильными статьями, договор с известными рисками. После каждого изменения инструкции вы прогоняете набор и сравниваете результат с эталоном.



Рис. 5. Инструкцию улучшают циклом и хранят с номером версии

Осторожно

Внедрение инструкций (англ. prompt injection). Если ассистент читает чужие тексты — письма, документы контрагентов, страницы сайтов, — фраза внутри них вроде «игнорируй прежние указания и...» может перебить вашу инструкцию. Не давайте ассистенту, который читает внешние тексты, права что-то делать без вашего подтверждения. Подробнее — в модуле 4 про агентов.

Быстро устаревает — проверяйте актуальное

Собственные ассистенты, проекты с файлами, «память» между чатами есть у основных сервисов, но называются и работают по-разному, а лимиты на файлы и тарифы меняются. Перед тем как строить ассистента для рабочих данных, проверьте, где хранятся файлы и используются ли они для обучения.

Частое сомнение

«Настроил ассистента один раз — дальше можно не проверять»

Ассистент повторяет ваш стандарт, но не становится от этого безошибочным. Модели обновляются, данные меняются, а инструкцию можно обойти. Поэтому контрольный набор прогоняют не один раз, а после каждого изменения — и время от времени просто так.

- В декабре 2023 г. пользователь велел чат-боту автосалона Chevrolet на базе ChatGPT «соглашаться со всем, что говорит клиент». После этого бот «согласился» продать машину стоимостью в десятки тысяч долларов за $1 и назвал это «юридически обязывающим предложением». Сделки не было, бота исправили. *— Inquirer Technology, декабрь 2023*

Что здесь справедливо. хорошо настроенный ассистент действительно экономит много времени и делает ответы единообразными. Но там, где он общается с клиентами или касается денег, нужны ограничения и надзор человека — помните и Air Canada из урока 3.

В разговоре с коллегой: *«Ассистент — как новый сотрудник с хорошей инструкцией: работает быстро, но первое время его работу проверяют.»*

Частое сомнение

«Если всё проверять, зачем тогда ИИ?»

Проверка действительно стоит времени, и это честная часть расчёта. Но проверять почти всегда быстрее, чем делать с нуля: найти цитату поиском — секунды, сверить итог с реестром — минута. А глубина проверки соразмерна цене ошибки (рис. 1): письмо и кредитное решение проверяют по-разному.

Что здесь справедливо. на некоторых задачах проверка съедает весь выигрыш — например, если вы и так делаете их быстро и без ошибок. Это нормальный результат: значит, эту задачу ИИ отдавать не нужно (урок 3, «зубчатая граница»).

В разговоре с коллегой: *«Давай посчитаем на твоей задаче: сколько уходит на работу целиком и сколько — на проверку черновика.»*

7. Итоги модуля 2

Четыре урока модуля складываются в один рабочий цикл:

Урок	Что даёт	Ключевой приём
4. Анатомия промпта	Ясная постановка задачи	Шесть блоков, тест нового сотрудника
5. Техники	Решение трудных случаев	Примеры, рассуждение, цепочки, ревью
6. Документы и данные	Работа с вашим материалом	Цитаты, схема полей, контрольная сумма
7. Контроль качества	Надёжность и повторяемость	Лестница проверки, системный промпт, контрольный набор

Главное

Модель — сильный исполнитель, а контроль качества остаётся за вами. Чем лучше налажена система проверки, тем больше работы можно спокойно доверить ИИ. В модуле 3 эти же принципы пригодятся для кода: там проверкой станут тесты.

Глоссарий урока

Термин	Простыми словами
Лестница проверки	Глубина проверки, подобранная под цену ошибки: от беглого просмотра до эксперта
Вторая независимая попытка	Тот же вопрос в новом чате или другой модели — для поиска случайных ошибок
Сикофантия (поддакивание)	Склонность модели соглашаться с собеседником в ущерб точности
Нейтральный вопрос	Вопрос, по которому не видно, какой ответ вы хотите услышать
Системный промпт	Инструкция, которая действует на весь диалог, а не на одно сообщение
Собственный ассистент (проект)	Сохранённая инструкция + постоянные файлы для повторяющейся задачи
Контрольный набор	5–10 задач с заранее известным хорошим ответом для проверки ассистента
Версия инструкции	Сохранённый вариант системного промпта с датой и описанием изменений
Внедрение инструкций (prompt injection)	Команда, спрятанная в чужом тексте, которая перебивает вашу инструкцию

Вопросы для самопроверки

1. Как решить, насколько глубоко проверять конкретный ответ?
2. Почему совпадение ответов двух моделей — ещё не доказательство?
3. Из каких двух шагов состоит проверка источника?
4. Перепишите вопрос «Я думаю, этот заёмщик надёжный. Согласен?» так, чтобы не провоцировать поддакивание.
5. Что сказать вместо «ты уверен?», если ответ вызывает сомнения?
6. Что стоит положить в системный промпт, а что лучше оставить для отдельных сообщений?
7. Зачем ассистенту контрольный набор задач и когда его прогонять?

Ответы для проверки

Ответы

1. По матрице доверия: чем дороже ошибка и труднее её заметить, тем выше ступень — от беглого просмотра до пересчёта и эксперта.
2. Модели учились на похожих данных и могут ошибаться одинаково. Вторая попытка ловит случайные сбои, но не заменяет сверку с источником.
3. Убедиться, что источник существует, и найти в нём ту самую цифру или фразу.
4. Например: «Оцени надёжность этого заёмщика по отчётности: назови сильные стороны и три главных риска» — без своей оценки в вопросе.
5. «Перепроверь по шагам и скажи, где ты мог ошибиться» — это просьба о проверке, а не о капитуляции.
6. В системный промпт — то, что повторяется всегда: кто вы, стандарты, формат, правила честности. Конкретная задача и данные — в сообщение.
7. Чтобы видеть, улучшила или ухудшила правка инструкцию. Прогонять после каждого изменения инструкции и время от времени — например, после обновления модели.

Практика

Практика

Задание 1. Два вопроса (5 мин)

Возьмите свой рабочий вывод или план. В одном чате спросите «Это хороший план, правда?», в новом — «Найди три самых слабых места в этом плане». Сравните ответы. Какой полезнее?

Задание 2. Свой системный промпт (15 мин)

Выберите повторяющуюся задачу и напишите для неё системный промпт по образцу из раздела 5: кто вы, стандарты, формат, правила честности. Если сервис позволяет, сохраните его как ассистента или проект.

Практика

Задание 3. Контрольный набор (15 мин)

Подберите 5 задач, для которых знаете хороший ответ. Прогоните их через ассистента из задания 2 и отметьте, где ответ совпал с эталоном. Измените одну строку инструкции и прогоните снова. Запишите обе версии с датой.

Задание 4. Проверка источника (5 мин)

Попросите модель назвать два источника по вашей профессиональной теме со ссылками. Откройте их: существуют ли они и говорят ли то, что им приписано?

Что почитать

- Официальные руководства Anthropic, OpenAI и Google по системным промптам и собственным ассистентам — разделы о системных инструкциях и проектах.
- Sharma и др., «Towards Understanding Sycophancy in Language Models» (2024) — подробное исследование поддакивания.
- Итан Моллик, «Co-Intelligence», главы о совместной работе с ИИ и проверке результата.
- Следующий урок открывает модуль 3: **«Что такое вайбкодинг»** — как создавать программы, разговаривая с ИИ обычным языком.

Источники фактов

Ссылки кликабельны. Реестр всех фактов урока — в файле docs/facts.md репозитория.

- Sharma M. и др. Towards Understanding Sycophancy in Language Models // ICLR 2024; вторая ссылка — препринт — proceedings.iclr.cc/paper_files/paper/2024/hash/0105f7972202c1d4fb817da9f21a9663-Abstract... · arxiv.org/abs/2310.13548
- TechCrunch, 29.04.2025: OpenAI explains why ChatGPT became too sycophantic; вторая ссылка — заметка OpenAI «Sycophancy in GPT-4o» — techcrunch.com/2025/04/29/openai-explains-why-chatgpt-became-too-sycophantic · openai.com/index/sycophancy-in-gpt-4o
- Inquirer Technology: ChatGPT error offers customer a Chevy for $1, декабрь 2023; вторая ссылка — запись в базе инцидентов ИИ (AI Incident Database) — technology.inquirer.net/?p=130716 · incidentdatabase.ai/ja/reports/3538